

EX[X] OCH V[X] FÖR FÖRDELNINGARNA

	E[X]	V[X]	mgf
Ber(p)	p	p(1-p)	
Bin(n, p)	np	np(1-p)	
Hyp(N, n, p)	np	np(1-p)*(N-n)/(N-1)	
Geo(p)	1/p	(1-p)/p ²	
NegBin(l, p)	l/p	l(1-p)/p ²	
Po(λ)	λ	λ	
Exp(λ)	1/λ	1/λ ²	
R(a, b)	(b-a)/2	(b-a) ² /12	
Gam(α, λ)	α/λ	α/λ ²	
N(μ, σ)	μ	σ ²	
χ ² (n)	n	2n	
t(student)	0	n/(n-2)	

Partialbråsuppdelning

$$\frac{f(x)}{(x-1)^n} = \frac{A_1}{(x-1)} + \frac{A_2}{(x-1)^2} + \dots + \frac{A_n}{(x-1)^n}$$

Definition E[x]

$$E[x^j] = \sum_k k^j f_x(k), \text{ diskret}$$

$$\int x^j f_x(x) dx, \text{ kontinuerlig}$$

Matrismultiplikation

$$\begin{pmatrix} A & B & C \\ D & E & F \\ G & H & I \end{pmatrix} = \begin{pmatrix} A^2 + BD + CG & AB + EB + CH & AC + IC + BF \\ AD + ED + FG & E^2 + BD + FH & CD + EF + IF \\ AG + IG + DH & BG + EH + IH & CG + FH - I \end{pmatrix}$$

$$\begin{pmatrix} A^2 + BD + CG & AB + EB + CH & AC + IC + BF \\ AD + ED + FG & E^2 + BD + FH & CD + EF + IF \\ AG + IG + DH & BG + EH + IH & CG + FH - I \end{pmatrix}$$

Räkeregler för E[x] och Var[x]

$$\text{Var } X = \frac{\sigma^2}{n}, \sigma^2 = \text{Var } x = E[X^2] - (E[X])^2$$

$$\text{Var}(aX + b) = a^2 \text{Var}(X)$$

$$E[aX + b] = aE[X] + b$$

$$E(Y^2) = m_{Y''}(0)$$

Generating function:

$$A(x) = \sum_{n=0}^{\infty} a_n x^n$$

Räkna ut:

$$\sum_{n=0}^{\infty} x^n = \frac{1}{1-x}$$

$$\sum_{n=0}^{\infty} (ax)^n = \frac{1}{1-ax}$$

$$\sum_{n=0}^{\infty} (-1)^n x^n = \frac{1}{1+x}$$

$$\sum_{n=0}^{\infty} x^{2n} = \frac{1}{1-x^2}$$

$$\sum_{n=0}^{\infty} \binom{n}{k} x^k = (1+x)^n$$

$$\sum_{n=0}^{\infty} \binom{n+k}{k} x^n = \frac{1}{(1-x)^{k+1}}$$

$$\sum_{n=0}^{\infty} \frac{x^n}{n!} = e^x$$

$$\sum_{n=0}^{\infty} \frac{x^{2n}}{(2n)!} = \frac{e^x + e^{-x}}{2}$$

$$\sum_{n=0}^{\infty} \frac{x^{2n+1}}{(2n+1)!} = \frac{e^x - e^{-x}}{2}$$

$$\sum_{n=0}^{\infty} \frac{x^{2n+1}}{(2n+1)!} = \frac{e^x - e^{-x}}{2}$$

Deriveringsregler

$$f(x) = Af'(x) = 0$$

Potensregeln

$$f(x) = x^n \rightarrow f'(x) = nx^{n-1}$$

Produktregeln

$$f(x) = g(x)h(x) \rightarrow f'(x) = g'(x)h(x) + g(x)h'(x)$$

Kvotregeln

$$f(x) = \frac{g(x)}{h(x)} \rightarrow f'(x) = \frac{g'(x)h(x) - g(x)h'(x)}{[h(x)]^2}$$

Derivata av exp.funktion

$$f(x) = e^{g(x)} \rightarrow f'(x) = g'(x)e^{g(x)}$$

Logaritmisk derivering

$$f(x) = \ln g(x) \rightarrow f'(x) = \frac{g'(x)}{g(x)}$$

Kedjeregeln

$$f(x) = g(u(x)) \rightarrow f'(x) = g'(u(x)) * u'(x)$$

Logaritm lagar (kan användas vid MLE)

$$10^x = y \leftrightarrow x = \lg y$$

$$e^x = y \leftrightarrow x = \ln y$$

$$\lg xy = \lg x + \lg y$$

$$\lg(x/y) = \lg x - \lg y$$

$$\lg x^p = p \lg x$$

$$1 / (1-x)^k = \sum \binom{k+n-1}{n} x^n$$

Uppgift 2)

Ge definitionen för en genererande funktion?

Den genererande funktionen för den oändliga

Sekvensen (g0, g1, g2, g3, ...) är:

$$G(x) = g_0 + g_1 x + g_2 x^2 + g_3 x^3 + \dots$$

Summan av den oändliga geometriska serien är:

$$1 + x + x^2 + x^3 + \dots = 1 / (1-x)$$

Vi vill hitta sekvensen (1, 4, 9, 16, ...)

$$(1, 1, 1, 1, \dots) \leftrightarrow 1 + x + x^2 + x^3 + \dots \leftrightarrow 1 / (1-x)$$

$$d/dx(1 + x + x^2 + x^3 + \dots) = d/dx(1 / (1-x))$$

$$1 + 2x + 3x^2 + 4x^3 + \dots = 1 / (1-x)^2$$

$$(1, 2, 3, 4, \dots) \leftrightarrow 1 / (1-x)^2$$

$$(0, 1, 2, 3, 4, \dots) \leftrightarrow x / (1-x)^2$$

$$d/dx(x / (1-x)^2) = (1+x) / (1-x)^3$$

$$(1, 4, 9, 16, \dots) \leftrightarrow (1+x) / (1-x)^3$$

Regler för genererande funktioner...

$$F(x) = (f_0, f_1, f_2, f_3, \dots)$$

$$G(x) = (g_0, g_1, g_2, g_3, \dots)$$

Multiplikation med konstant

$$c * F(x) = (c*f_0, c*f_1, c*f_2, c*f_3, \dots)$$

Additions regeln...

$$F(x) + G(x) = (f_0+g_0, f_1+g_1, f_2+g_2, f_3+g_3, \dots)$$

Högerskift (Lägga till n st nollor i början av sekvens)

$$\begin{aligned} \underbrace{(0, 0, \dots, 0, f_0, f_1, f_2, \dots)}_{k \text{ zeroes}} &\leftrightarrow f_0 x^k + f_1 x^{k+1} + f_2 x^{k+2} + \dots \\ &= x^k * (f_0 + f_1 x + f_2 x^2 + f_3 x^3 + \dots) \\ &= x^k F(x). \end{aligned}$$

Derivering av sekvens..

$$d/dx(1 + x + x^2 + \dots) = d/dx(1 / (1-x))$$

$$1 + 2x + 3x^2 + \dots = d/dx(1 / (1-x)^2)$$

Multiplitera två sekvenser exempel)

$$(1, 2, 3, 4, \dots) \leftrightarrow 1 / (1-x)^2$$

$$(5, 6, 0, 0, \dots) \leftrightarrow 5+6x$$

$$(5*1, 5*2+6*1, 5*3+6*2+0*1, 5*4+6*3+2*0*1, \dots)$$

Exempel på vanliga sekvenser)

$$(1, 1, 1, 1, \dots) \leftrightarrow 1 / (1-x)$$

$$(1, 2, 3, 4, \dots) \leftrightarrow d/dx(1 / (1-x)) = 1 / (1-x)^2$$

$$(0, 1, 2, 3, \dots) \leftrightarrow x / (1-x)^2$$

$$(1, 4, 9, 16, \dots) \leftrightarrow d/dx(x / (1-x)^2) = (1+x) / (1-x)^3$$

$$(0, 1, 4, 9, \dots) \leftrightarrow x(1+x) / (1-x)^3$$

$$(1, -1, 1, -1, \dots) \leftrightarrow 1 / (1+x)$$

$$(0, 1, 0, \dots) \leftrightarrow 1 / (1-x^2)$$

$$(2, 0, 2, 0, \dots) \leftrightarrow 2 / (1-x^2)$$

$$(0, 1, 1, 0, 0, 0, \dots) \leftrightarrow x \frac{1-x^2}{1-x}$$

Vad kan man använda generating functions till?

Genererande funktioner är särskilt användbara till att

lösa problem av typen "på hur många sätt kan man välja

n st föremål ur ett set". Koefficienten framför x^n talar om

på hur många olika sätt vi kan välja n stycken föremål.

Till exempel, den genererande funktionen för binomial

koefficienter och genererande funktionen för att välja

föremål från k element set med repetition.

Generellt fall för MLE:

Multiplitera ihop alla funktioner.

Ta log av de multiplicerade funktionerna.

Derivera och sätt = 0

Lös ut variabel

$$f(x_1, x_2, x_3, \dots | a) = f(x_1 | a) * f(x_2 | a) * \dots = \text{lik}(a)$$

$$\text{lik}(a) = \prod f(x_i | a)$$

$$\ln(\text{lik}(a)) = l(a) = \sum (\ln f(x_i | a))$$

$$d/dx(\ln(\text{lik}(a))) = 0$$

Uppgift 3) Bevis för linear regression line..

Låt S representera "Sum of errors". Genom hela beviset är

nedregränsen för summaformeln i = 1 och övre är n.

$$\text{Vi vill nu minimera SSE mha partiell derivat: } S = \sum (y - b_0 - b_1 x)^2$$

$$\frac{dS}{db_1} = -2 \sum x(y - b_0 - b_1 x)$$

$$\frac{dS}{db_0} = -2 \sum (y - b_0 - b_1 x)$$

Sätt derivatan till lika med 0.

$$0 = -2 \sum x(y - b_0 - b_1 x)$$

$$0 = -2 \sum (y - b_0 - b_1 x)$$

$$0 = \sum (xy - xb_0 - b_1 x^2)$$

$$0 = \sum y - \sum b_0 - \sum b_1 x$$

$$0 = \sum xy - \sum xb_0 - \sum b_1 x^2$$

$$0 = \sum y - nb_0 - b_1 \sum x$$

$$0 = \sum xy - b_0 \sum x - b_1 \sum x^2 \quad (*)$$

$$b_0 = \frac{\sum y - b_1 \sum x}{n} \quad (**)$$

Substituerar (**) i (*)

$$0 = \sum xy - b_0 \sum x - b_1 \sum x^2 = \sum xy - \left(\frac{\sum y - b_1 \sum x}{n} \right) \sum x - b_1 \sum x^2$$

En jävla massa algebra..

$$0 = \sum xy - \left(\frac{\sum y - b_1 \sum x}{n} \right) \sum x - b_1 \sum x^2 \quad b_0 = \frac{\sum y - b_1 \sum x}{n}$$

$$0 = \sum xy - \left(\frac{\sum x \sum y - b_1 \sum x \sum x}{n} \right) - b_1 \sum x^2 \quad b_0 = \frac{\sum y}{n} - \frac{b_1 \sum x}{n}$$

$$0 = n \sum xy - \sum x \sum y + b_1 (\sum x)^2 - nb_1 \sum x^2 \quad b_0 = \bar{y} - b_1 \bar{x}$$

$$nb_1 \sum x^2 - b_1 (\sum x)^2 = n \sum xy - \sum x \sum y \quad b_0 = \bar{y} - b_1 \bar{x}$$

$$b_1 (n \sum x^2 - (\sum x)^2) = n \sum xy - \sum x \sum y \quad b_1 = \frac{n \sum xy - \sum x \sum y}{n \sum x^2 - (\sum x)^2}$$

Simple way to calculate linear regression)

$$Y(\text{tak}) = b_0 + b_1 X$$

$$b_0 = y_{(\text{mean})} - b_1 x_{(\text{mean})}$$

$$b_1 = (x_{(\text{mean})} * y_{(\text{mean})} - (x^* y)_{(\text{mean})}) / (x_{(\text{mean})}^2 - x^2_{(\text{mean})})$$

Exempel)

$$(7.3, 10.2), (3.2, 6.5), (8.7, 14), (6.4, 9.9), (1.1, 3.6), (2.6, 5.9)$$

Hitta least square regression line y= ax + b..

$$X_{(\text{mean})} = (7.3+3.2+8.7+6.4+1.1+2.6)/6 = 4.8833..$$

$$Y_{(\text{mean})} = (10.2+6.5+14+9.9+3.6+5.9)/6 = 8.35$$

$$(x^* y)_{(\text{mean})} = (7.3*10.2 + 3.2*6.5 + 8.7*14 + 6.4*9.9 + 1.1*3.6 + 2.6*5.9)/6 = 49.9533..$$

$$x^2_{(\text{mean})} = (7.3^2 + 3.2^2 + 8.7^2 + 6.4^2 + 1.1^2 + 2.6^2)/6 =$$

$$31.35833..$$

$$B_1 = (4.8833 * 8.35 - 49.9533) / (4.8833^2 - 31.3583) = 1.2218$$

$$B_0 = 8.35 - 1.2218 * 4.8833 = 2.38358406$$

$$\text{SSE} := (10.2 - 2.38358406 - 1.2218*7.3)^2 + (6.5 - 2.38358406 - 1.2218*3.2)^2 + (14 - 2.38358406 - 1.2218*8.7)^2 + (9.9 - 2.38358406 - 1.2218*6.4)^2 + (3.6 - 2.38358406 - 1.2218*1.1)^2 + (5.9 - 2.38358406 - 1.2218*2.6)^2 = 2.455959$$

$$\text{SSR} = \sum (y_{(\text{tak})} - y_{(\text{mean})})^2 = \sum (b_0 + b_1 * x - y_{(\text{mean})})^2$$

$$\text{SST} = \text{SSR} + \text{SSE}$$

$$\text{SSE} := (10.2 - 2.38358406 - 1.2218*7.3)^2 + (6.5 - 2.38358406 - 1.2218*3.2)^2 + (14 - 2.38358406 - 1.2218*8.7)^2 + (9.9 - 2.38358406 - 1.2218*6.4)^2 + (3.6 - 2.38358406 - 1.2218*1.1)^2 + (5.9 - 2.38358406 - 1.2218*2.6)^2 = 2.455959$$

$$\text{SSR} = \sum (y_{(\text{tak})} - y_{(\text{mean})})^2 = \sum (b_0 + b_1 * x - y_{(\text{mean})})^2$$

$$\text{SST} = \text{SSR} + \text{SSE}$$

Vad används linear regressions till?

If the goal is prediction, or forecasting, or reduction, linear

regression can be used to fit a predictive model to an

observed data set of y and X values. After developing such a

model, if an additional value of X is then given without its

accompanying value of y, the fitted model can be used to

make a prediction of the value of y.

Given a variable y and a number of variables X1, ..., Xp that

may be related to y, linear regression analysis can be applied

to quantify the strength of the relationship between y and

the Xj, to assess which Xj may have no relationship with y at

all, and to identify which subsets of the Xj contain redundant

information about y.

Fördelar mellan mm och mle:

Mle är att föredra över mm i de flesta fall

eftersom att mle maximerar sannolikheten att de

stämmer och att mm tar ett medelvärde från en

del av populationen och behöver därav inte vara

speciellt precis.

Dock ger MLE och MM oftast samma resultat.

Uppgift 1)

Markov egenskapen defineras;

Låt $\{X(t), t = 0, 1, 2, \dots\}$ vara en stokastisk process i diskret tid. Då har processen Markovegenskapen om:
För alla $n \in \mathbb{N}$, och alla tillstånd $i, j, s_k, k = 0, 1, 2, \dots, n - 1$, så gäller
 $P\{X(n+1) = j | X(n) = i, X(k) = s_k, k = 0, 1, \dots, n-1\} = P\{X(n+1) = j | X(n) = i\}$

Definition för markovkedja..

Definition 3.1 $\{X_n; n \geq 0\}$ är en Markovkedja om

$$P(X_{n+1} = i_{n+1} \mid X_0 = i_0, X_1 = i_1, \dots, X_n = i_n) = P(X_{n+1} = i_{n+1} \mid X_n = i_n)$$

för alla n och tillstånd i_0, i_1, \dots, i_{n+1} .

Definition 3.2 Övergångssannolikheterna p_{ij} i en tidshomogen Markovkedja definieras av

$$p_{ij} = P(X_n = j \mid X_{n-1} = i) \quad i, j \in E$$

d.v.s. p_{ij} är sannolikheten att gå från i till j i ett tidssteg.

Definition 3.3 Med övergångsmatrisen P menas matrisen $(p_{ij})_{i,j \in E}$ av övergångssannolikheter

$$P = \begin{pmatrix} p_{11} & p_{12} & p_{13} & \dots \\ p_{21} & p_{22} & p_{23} & \dots \\ p_{31} & p_{32} & p_{33} & \dots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}. \tag{3.4}$$

Definition 3.4 Startfördelningen är fördelningen för X_0 och den anges av vektorn

$$\mathbf{p}^{(0)} = (p_1^{(0)}, p_2^{(0)}, p_3^{(0)}, \dots)$$

där $p_k^{(0)} = P(X_0 = k)$. Fördelningen för X_n anges av vektorn

$$\mathbf{p}^{(n)} = (p_1^{(n)}, p_2^{(n)}, p_3^{(n)}, \dots)$$

där $p_k^{(n)} = P(X_n = k)$.

Låt övergångssannolikheterna mellan tillstånden i en markovkedja betecknas med $P_{ij} = P(X_{n+1} = j | X_n = i)$, och låt

$$m_i = E[\text{antal steg tills kedjan når ett absorberande tillstånd då man startar i } i],$$

Man kan visa att

$$m_i = \begin{cases} 0 & \text{om } i \text{ är absorberande} \\ 1 + \sum_k P_{ik} m_k & \text{annars} \end{cases}$$

Låt a vara ett absorberande tillstånd och låt $q_i = P(\text{kedjan absorberas i tillstånd } a \text{ då man startar i tillstånd } i)$. Då gäller att

$$q_i = \begin{cases} 1 & \text{om } i = a \\ 0 & \text{om } i \text{ är absorberande, men } i \neq a \\ \sum_k P_{ik} q_k & \text{annars} \end{cases}$$

Sats 3.1 (Chapman-Kolmogorov)

a) $p_{ij}^{(m+n)} = \sum_{k \in E} p_{ik}^{(m)} p_{kj}^{(n)}$

b) $P^{(m+n)} = P^{(m)} P^{(n)}$

c) $P^{(n)} = P^n$

d) $\mathbf{p}^{(n)} = \mathbf{p}^{(0)} P^{(n)} = \mathbf{p}^{(0)} P^n$.

If X_1, \dots, X_n are iid Normal(μ, σ^2), their joint density is the product of their marginal densities:

$F(X_1, \dots, X_n \mid \mu, \sigma) = \prod \frac{1}{\sigma \sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left[\frac{(X_i - \mu)^2}{\sigma^2} \right] \right\}$
Regarded as a function of μ and σ , this is the likelihood function. The log likelihood is thus;
 $L(\mu, \sigma) =$

$$-n \cdot \log \sigma - n/2 \cdot \log 2\pi - \frac{1}{2\sigma^2} \sum (X_i - \mu)^2$$

The partials with respect to μ and σ are:

$$dL/d\mu \Rightarrow \frac{1}{\sigma^2} \sum (X_i - \mu)$$

$$dL/d\sigma \Rightarrow -n/\sigma + \sigma^{-3} \sum (X_i - \mu)^2$$

Setting the first partial to zero and solve for mle

gives; $\mu(TAK) = x_{(mean)}$

Setting the second partial to zero and substituting the mle for μ we find the mle:

$$\text{Gives; } \sigma(TAK) = \sqrt{\frac{1}{n} \sum (X_i - x_{(mean)})^2}$$

If X follows poisson distribution with parameter λ then

$P(X = x) = \lambda^x e^{-\lambda} / x!$ If x_1, \dots, x_n are iid and poisson their joint frequency function is the product of the marginal frequency functions. The log likelihood is thus;

$$L(\lambda) = \sum (X_i \log \lambda - \lambda - \log X_i!)$$

$$= \log \lambda \sum X_i - n\lambda - \sum \log X_i!$$

Settin the first derivate of the log likelihood equal to zero we find:

$$L'(\lambda) = (1/\lambda) \sum X_i - n = 0$$

The mle is then;

$$\text{Lambda(TAK)} = x_{(mean)}$$

Uppgift 4)

Let X_1, X_2, \dots, X_n be Bernoulli random variables with parameter p . What is the method of moments estimator of p ?

$E(X_i) = p$

We have just one parameter for which we are trying to derive the method of moments estimator. Therefore, we need just one equation. Equating the first theoretical moment about the origin with the corresponding sample moment, we get: (SUMMA FORMELN GÅR MELLAN i=1 och n)

$$p = (1/n) \sum X_i$$

Gör om p till en estimator (sätt en hatt på p):

$$\hat{p} = (1/n) \sum X_i$$

So, in this case, the method of moments estimator is the same as the maximum likelihood estimator, namely, the sample proportion.

Let X_1, X_2, \dots, X_n be normal random variables with mean μ and variance σ^2 . What are the method of moments estimators of the mean μ and variance σ^2 ?

$$E(X_i) = \mu \quad \text{and} \quad E(X_i^2) = \sigma^2 + \mu^2$$

$$E(x) = \mu = (1/n) \sum X_i \quad (\text{SUMMA FORMELN GÅR MELLAN i=1 och n})$$

$$E(X^2) = \sigma^2 + \mu^2 = (1/n) \sum X_i^2$$

Now, the first equation tells us that the method of moments estimator for the mean μ is the sample mean:

$$\mu_{MM} = (1/n) \sum X_i = X_{(mean)}$$

And, substituting the sample mean in for μ in the second equation and solving for σ^2 , we get that the method of moments estimator for the variance σ^2 is:

$$\sigma_{MM}^2 = (1/n) \sum X_i^2 - \mu^2 = (1/n) \sum X_i^2 - X_{(mean)}^2$$

which can be rewritten as:

$$\sigma_{MM}^2 = (1/n) \sum (X_i - X_{(mean)})^2$$

Again, for this example, the method of moments estimators are the same as the maximum likelihood estimators.

Suppose that X follows a geometric distribution, $P(X = K) = p(1-p)^{K-1}$ and assume an iid sample of size n . Find the method of moments estimator for p : ($i = 1$ och övregräns oändligheten)

$$E(X) = \sum kp(1-p)^{k-1} = p \cdot \sum k(1-p)^{k-1} = p / (1-(1-p))^2 = 1/p$$

So the MME estimator of p is $\hat{p} = 1 / x_{(mean)}$

Let X_1, \dots, X_n be iid Binomial(n, p), that is, $P(X_i = x \mid n, p) = \binom{n}{x} p^x (1-p)^{n-x}$, $x = 0, 1, \dots, n$.

Here we assume that both k and p are unknown and we desire point estimators for both parameters.

$$X_{(mean)} = np$$

$$(1/n) \sum X_i^2 = np(1-p) + n^2 p^2, \text{ Solving for } n \text{ and } p \text{ yields the estimators.}$$

$$n = (X_{(mean)}^2 / X_{(mean)}) - (1/n) \sum (X_i - X_{(mean)})^2 \text{ and } P = X_{(mean)} / n$$

method of moments poisson; To estimate parameter λ of Poisson(λ) distribution, we recall that $\mu_1 = E(X) = \lambda$

There is only one unknown parameter, hence we write one equation,

$$\mu_1 = \lambda = m_1 = X_{(mean)}$$

"Solving" it for λ , we obtain $\lambda_{(mean)} = X_{(mean)}$,

the method of moments estimator of λ .

MLE geometric; Let $X_1, X_2, X_3, \dots, X_n$ be a random sample from the geometric distribution with p.d.f.

$$f(x; p) = (1-p)^{x-1} p, x = 1, 2, 3, \dots \text{ The likelihood function is given by:}$$

$$L(p) = (1-p)^{x_1-1} p (1-p)^{x_2-1} p \dots (1-p)^{x_n-1} p = p^n (1-p)^{\sum_{i=1}^n x_i - n}$$

taking log,

$$\ln L(p) = n \ln p + \left(\sum_{i=1}^n x_i - n \right) \ln(1-p) \text{ Differentiating and equating to zero, we get,}$$

$$\frac{d[\ln L(p)]}{dp} = \frac{n}{p} - \frac{(\sum_{i=1}^n x_i - n)}{(1-p)} = 0 \quad \text{THEREFORE,}$$

$$p = \frac{n}{(\sum_{i=1}^n x_i)} \text{ So, the maximum likelihood estimator of } P \text{ is:}$$

$$P = \frac{n}{(\sum_{i=1}^n X_i)} = \frac{1}{\bar{X}}$$

MLE BERNOULLI: Since X_1, X_2, \dots, X_n are iid random variables, the joint distribution is

$L(p; x) \approx f(x; p) = \prod f(x_i; p) = \prod p^x (1-p)^{1-x}$ Differentiating the log of $L(p; x)$ with respect to p and setting the derivative to zero shows that this function achieves a maximum at

$$p^{\wedge} = (1/n) \sum x_i$$

MLE binomial: Suppose that X is an observation from a binomial distribution, $X \sim \text{Bin}(n, p)$, where n is known and p is to be estimated. The likelihood function is:

$L(p; x) = n! / (x! (n-x)!) \cdot p^x (1-p)^{n-x}$ which, except for the factor $n! / (x! (n-x)!)$ is identical to the likelihood from n independent bernoulli trials with $p = (1/n) \sum X_i$.

But since likelihood is regarded as a function only of parameter p the factor is just a fixed constant and does not affect the MLE. Therefore, $p = x/n$